

Данилов Сергей Дмитриевич

Санкт-Петербург, Россия · +7 (986) 767-86-96 @geniusserg

danilovsergeyd@vk.com linkedin.com/in/geniusserg

> ML/LLM-инженер по инференсу — владеет полным циклом оптимизации LLM-инференса.

Оптимизация инференса — Отвечаю за оптимизацию LLM-обслуживания и достижение высокой надёжности: исследую новые алгоритмы, моделирую и валидирую их влияние, а затем внедряю их заказчикам. В мои задачи входят выбор лучшей DP/TP-стратегии через моделирование инференс-кластеров на 10 тыс. узлов, настройка планирования реплик и эксперименты с различными стратегиями размещения MoE EPLB; планирование с учётом надёжности на основе статистических подходов и дискретно-событийных симуляций; LLMOps-методологии для обслуживания и деплоя кода оптимизации, а также поддержка исследовательских проектов по квантизации LLM.

Предиктивная надёжность — Отвечаю за прогнозирование отказов и оценку доступности (моделирование по Вейбуллу) аппаратной части инференс-кластера (память, NPU, сеть) и ПО (vLLM, VeRL, agent-воркфлоу).

ОПЫТ РАБОТЫ

Huawei — R&D-инженер по LLM-инференсу · *Сентябрь 2024 – настоящее время*

- Разработал топологически-зависимые комбинаторные алгоритмы размещения экспертов EPLB MoE, совместно оптимизирующие маппинг «эксперт → NPU» с all-to-all-коммуникациями и fused-ядрами для минимизации перегрузки сети и хвостовой задержки — до 10% снижения сетевого дисбаланса и 5% улучшения TPOT (95% ДИ ±1%).
- LLMOps для проекта квантизации LLM: вёл весь цикл от исследовательского ноутбука → квантованная модель → задеплоенный сервис и бенчмарки. Ускорил цикл исследований в 3 раза (использовал PyTorch, vLLM, DeepEval).
- Симулятор disaggregated Prefill/Decode инференс-кластера — дискретно-событийное моделирование на Python распределённой системы prefill/decode с балансировкой нагрузки с учётом локальности KV-кэша и генератором марковского трафика запросов; тестировал гипотезы по выбору топологии TP/DP/SP/EP, политики планирования и быстрого восстановления после сбоев для удержания SLO заказчика 99,99%. Тот же симулятор использовался для тестирования стратегии восстановления RL-воркеров (VeRL): время восстановления снижено с 10 до 5 минут, а падение TPOT при сбоях — не более 5%.
- Спроектировал NUMA-aware стресс-тест памяти, достигший 95% теоретической пропускной способности; по его результатам смоделировал MTTR распределением Вейбулла и построил модель прогнозирования отказов (XGBoost), снизившую издержки от ошибок памяти в два раза. документация
- Обучил модель кластеризации временных рядов телеметрии оптоволокна, которая заранее выявляет деградирующие каналы; модель с минимальным числом параметров (1 млн параметров), работающая на малых чипах, повысила доступность кластера на +10% без

требования к signal-to-noise — только сырые показатели оптических датчиков без разметки падений связи. Использовал sktime для статистического и ML-анализа временных рядов и PyTorch для обучения модели.
- Интегрировал свои проекты как MCP-инструменты во внутреннюю лабораторию Harness-агентов.

ML-инженер — Университет ИТМО · *Ноябрь 2023 – Сентябрь 2024*

- Сбер и ИТМО: спроектировал эмулятор пользователей на CTGAN, применил синтезированные данные при обучении BiVAE для ленты VK и добился улучшения метрики MAP@5 на 3% при тесте на открытых данных.
- Алмазова и ИТМО: применил исследование из магистерского диплома по ранжированию малых данных с помощью чисел Шепли при обучении модели XGBoost для предсказания успеха лечения ожирения; улучшил точность с 65% до 71% (+7%) в прогнозе ответа на терапию сибутрамином за 3 месяца; 2 статьи Q2. J. Pers. Med. J. Clin. Med.
- Промышленный ИИ-ассистент: улучшил NER по PDF с помощью prompt engineering/self-consistency; фильтрация убрала 80% повторов.

Инженер по тестированию — Harman · *Сентябрь 2021 – Июль 2022*

- Ускорил тестирование сложных автомобильных GPS-систем с помощью Robot Framework

Release-инженер — Intel · *Июль 2019 – Август 2021*

- Поддерживал release-инфраструктуру Intel OneAPI HPC: автоматизация установочных алгоритмов на Python/Bash и разработка Desktop-инсталлятора.

ТЕХНОЛОГИИ

- **AI-инфраструктура:** Harness, Agents workflow, RAG, CAG, vLLM, VeRL, PyTorch, Kubernetes
- **Анализ данных и исследования:** Python, Pandas, Scikit-learn, AutoML, PatentScope, Elsevier Scopus

ОБРАЗОВАНИЕ

Университет ИТМО, 2024 — магистратура по анализу данных

– Диплом: Фильтрация сэмплов с весами Шепли для ML на малых выборках; +7% точности на малых медицинских данных.

НИУ ВШЭ, 2022 — бакалавриат по программной инженерии

– Диплом: доступный ассистент для слабовидящих пользователей на базе Yandex Cloud OCR.

ПУБЛИКАЦИИ

- Google Scholar · индекс Хирша 2
- Danilov et al., J. Pers. Med. 2024, 14, 811 — прогнозирование терапии сибутрамином.
- Markina et al., J. Clin. Med. 2024, 13, 4151 — статистические методы для исследования бурой жировой ткани и её влияния на лечение ожирения.

ХАКАТОНЫ

ScienceRAG — исследовательский ассистент-агент на базе GigaChat

– ScienceRAG: улучшил RAG-поиск по arXiv с помощью агента на основе GigaChat

YouTube

X5 AI Tech Hackathon — алгоритм детекции галлюцинаций

– X5 AI Tech: детектор галлюцинаций на ruBERT — точность 88%, инференс <0,45 с; топ-10.

ЯЗЫКИ

• Русский, Английский (B1)