

Данилов Сергей Дмитриевич

Санкт-Петербург, Россия · +7 (986) 767-86-96 @geniusserg

danilovsergeyd@vk.com linkedin.com/in/geniusserg

> ML/LLM-инженер по инференсу — владеет полным циклом эксплуатации LLM в продакшене и оптимизацией инференса.

Оптимизация инференса — Отвечаю за оптимальную высокодоступную оптимизацию инференса — выбор лучшей DP/TP-стратегии, планирование реплик и стратегии размещения экспертов EPLB MoE на кластере 256+ узлов; планирование с учётом надёжности с полноценной симуляцией системы; LLMOps для оптимизации и квантизации vLLM.

Предиктивная надёжность — Отвечаю за прогнозирование отказов и оценку доступности (моделирование по Вейбуллу) аппаратной части инференс-кластера (память, NPU, сеть) и ПО (vLLM, VeRL, agent-воркфлоу).

ОПЫТ РАБОТЫ

Huawei — R&D-инженер по LLM-инференсу · *Сентябрь 2024 – настоящее время*

- Разработал топологически-зависимые комбинаторные алгоритмы размещения экспертов EPLB MoE, совместно оптимизирующие маппинг «эксперт → NPU» с all-to-all-коммуникациями и fused-ядрами для минимизации перегрузки сети и хвостовой задержки — до 10% снижения сетевого дисбаланса и 5% улучшения TPOT (95% ДИ ±1%).
- LLMOps для проекта квантизации LLM: вёл весь цикл от исследовательского ноутбука → квантованная модель → задеплоенный сервис и бенчмарки, ускорив цикл исследований в 3 раза (PyTorch, vLLM, DeepEval).
- Симулятор disaggregated Prefill/Decode — дискретно-событийное моделирование на Python системы prefill/decode-обслуживания с балансировкой нагрузки с учётом KV-кэша и генератором марковского трафика запросов; выбор топологии TP/DP/SP/EP, политики планирования и восстановления после сбоев для удержания SLO 99,99%. Тот же симулятор использовался для тестирования стратегии восстановления RL-воркеров (VeRL): время восстановления снижено с 10 до 5 минут, а падение TPOT при сбоях — не более 5%.
- NUMA-осознанное стресс-тестирование достигло 95% теоретической пропускной способности; моделирование MTTR (распределение Вейбулла) + прогнозирование отказов (XGBoost) снизили издержки от ошибок памяти в два раза. документация
- Кластеризация временных рядов телеметрии оптической мощности заранее выявляет деградирующие каналы; модель с минимальным числом параметров (1 млн параметров), работающая на малых чипах, повысила доступность кластера на +10% (без требования к signal-to-noise — только сырые данные оптических датчиков). Использовал sktime для статистического и ML-анализа временных рядов и PyTorch для кластеризации и поиска паттернов.

ML-инженер — Университет ИТМО · *Ноябрь 2023 – Сентябрь 2024*

- Сбер и ИТМО: эмулятор пользователей на CTGAN; улучшил MAP@5 рекомендательной системы BiVAE на 3%.
- Алмазова и ИТМО: взвешенный XGBoost с весами Шепли для лечения ожирения; точность 71% в прогнозе ответа на терапию сибутрамином за 3 месяца; 2 статьи Q2. J. Pers. Med. J. Clin. Med.
- Промышленный ИИ-ассистент: улучшил NER по PDF с помощью prompt engineering/self-consistency; фильтрация убрала 80% повторов.

Инженер по тестированию — Harman · *Сентябрь 2021 – Июль 2022*

- Ускорил тестирование сложных автомобильных GPS-систем с помощью Robot Framework

Release-инженер — Intel · *Июль 2019 – Август 2021*

- Поддерживал release-инфраструктуру Intel OneAPI HPC: автоматизация на Python/Bash и инсталлятор.

ТЕХНОЛОГИИ

- **AI-инфраструктура:** Harness, Agents workflow, RAG, CAG, vLLM, VeRL, PyTorch, Kubernetes
- **Анализ данных и исследования:** Python, Pandas, Scikit-learn, AutoML, PatentScope, Elsevier Scopus

ОБРАЗОВАНИЕ

Университет ИТМО, 2024 — магистратура по анализу данных

– Диплом: фильтрация с весами Шепли для ML на малых выборках; +7% точности на медицинских данных.

НИУ ВШЭ, 2022 — бакалавриат по программной инженерии

– Диплом: доступный ассистент для слабовидящих пользователей на базе Yandex Cloud OCR.

ПУБЛИКАЦИИ

- Google Scholar · индекс Хирша 2
- Danilov et al., J. Pers. Med. 2024, 14, 811 — прогнозирование терапии сибутрамином.
- Markina et al., J. Clin. Med. 2024, 13, 4151 — бурая жировая ткань и лечение ожирения.

ХАКАТОНЫ

ScienceRAG — исследовательский ассистент-агент на базе GigaChat

– ScienceRAG: улучшил RAG-поиск по arXiv на GigaChat YouTube

X5 AI Tech Hackathon — алгоритм детекции галлюцинаций

– X5 AI Tech: детектор галлюцинаций на ruBERT — точность 88%, инференс <0,45 с; топ-10.

ЯЗЫКИ

- Русский, английский (B1)