

Данилов Сергей Дмитриевич

Санкт-Петербург, Россия · +7 (986) 767-86-96 @geniusserg

danilovsergeyd@vk.com linkedin.com/in/geniusserg

> ML/LLMOps-инженер — владеет полным циклом эксплуатации LLM в продакшене и оптимизацией инференса.

Оптимизация инференса — EPLB-размещение экспертов MoE + квантизация FP8/INT8: отвечаю от разработки алгоритма до multi-node-деплоя в vLLM, бенчмарков и дашбордов; LLMOps проекта квантизации — ноутбук → модель → сервис, цикл исследований быстрее в 3 раза.

Serving и планирование — Симулятор disaggregated Prefill/Decode (Python): отвечаю за выбор топологии TP/DP/SP/EP и политики планирования для удержания SLO 99,99% и восстановление vLLM.

Предиктивная надёжность — Прогнозирование отказов памяти (NUMA/Вейбулл) + кластеризация телеметрии оптики: отвечаю за +10% доступности кластера и снижение издержек в 2 раза.

ОПЫТ РАБОТЫ

Huawei — R&D-инженер по LLM-инференсу · *Сентябрь 2024 – настоящее время*

- Комбинаторные алгоритмы размещения экспертов MoE (EPLB), совместно оптимизирующие маппинг «эксперт → GPU» и all-to-all-коммуникации, чтобы минимизировать перегрузку сети и хвостовую задержку; та же платформа использовалась для multi-node-деплоя оптимизированных EPLB-алгоритмов в vLLM, запуска бенчмарков и построения подробных дашбордов.
- LLMOps для проекта квантизации LLM: вёл весь цикл от исследовательского ноутбука → квантованная модель → задеплоенный сервис и бенчмарки, ускорив цикл исследований в 3 раза.
- Глубокое знание стека обслуживания: continuous batching и вытесняющее планирование, fused-коммуникации, квантизация FP8/INT8, спекулятивное декодирование и trade-off оптимизации.
- Симулятор disaggregated Prefill/Decode — дискретно-событийное моделирование на Python системы prefill/decode-обслуживания с балансировкой нагрузки с учётом KV-кэша и марковским трафиком запросов; выбор топологии TP/DP/SP/EP и политики планирования для удержания SLO 99,99%; восстановление vLLM для RL-прогонов.
- NUMA-осознанное стресс-тестирование достигло 95% теоретической пропускной способности; моделирование MTTR (распределение Вейбулла) + прогнозирование отказов (XGBoost) благодаря раннему предупреждению снизили издержки от ошибок памяти в big data приложениях в два раза. документация
- Кластеризация временных рядов телеметрии оптической мощности заранее выявляет деградирующие каналы; модель с минимальным числом параметров повысила доступность кластера на +10%.

ML-инженер — Университет ИТМО · *Ноябрь 2023 – Сентябрь 2024*

- Сбер и ИТМО: эмулятор пользователей на CTGAN; улучшил MAP@5 рекомендательной системы BiVAE на 3%.
- Алмазова и ИТМО: взвешенный XGBoost с весами Шепли для лечения ожирения; точность 71% в прогнозе ответа на терапию сибутрамином за 3 месяца; 2 статьи Q2. J. Pers. Med. J. Clin. Med.
- Промышленный ИИ-ассистент: улучшил NER по PDF с помощью prompt engineering/self-consistency; фильтрация убрала 80% повторов.

Инженер по тестированию — Harman · *Сентябрь 2021 – Июль 2022*

- Ускорил тестирование сложных автомобильных GPS-систем с помощью Robot Framework

Release-инженер — Intel · *Июль 2019 – Август 2021*

- Поддерживал release-инфраструктуру Intel OneAPI HPC: автоматизация на Python/Bash и инсталлятор.

ТЕХНОЛОГИИ

- **AI-инфраструктура:** Harness, Agents workflow, RAG, CAG, vLLM, VeRL, PyTorch, Kubernetes
- **Анализ данных и исследования:** Python, Pandas, Scikit-learn, AutoML, PatentScope, Elsevier Scopus

ОБРАЗОВАНИЕ

Университет ИТМО, 2024 — магистратура по анализу данных

– Диплом: фильтрация с весами Шепли для ML на малых выборках; +7% точности на медицинских данных.

НИУ ВШЭ, 2022 — бакалавриат по программной инженерии

– Диплом: доступный ассистент для слабовидящих пользователей на базе Yandex Cloud OCR.

ПУБЛИКАЦИИ

- Google Scholar · индекс Хирша 2
- Danilov et al., J. Pers. Med. 2024, 14, 811 — прогнозирование терапии сибутрамином.
- Markina et al., J. Clin. Med. 2024, 13, 4151 — бурая жировая ткань и лечение ожирения.

ХАКАТОНЫ

ScienceRAG — исследовательский ассистент-агент на базе GigaChat

– ScienceRAG: улучшил RAG-поиск по arXiv на GigaChat YouTube

X5 AI Tech Hackathon — алгоритм детекции галлюцинаций

– X5 AI Tech: детектор галлюцинаций на ruBERT — точность 88%, инференс <0,45 с; топ-10.

языки

- Русский, английский (B1)