



Данилов Сергей Дмитриевич

Санкт-Петербург, Россия · +7 (986) 767-86-96

[➤ @geniusserg](#)

[✉ danilovsergeyd@vk.com](mailto:danilovsergeyd@vk.com)

[in linkedin.com/in/geniusserg](https://www.linkedin.com/in/geniusserg)

ML/LLMOps-инженер, который владеет полным циклом эксплуатации ML и LLM в продакшене — деплой моделей, распределённый инференс, оркестрация GPU, vLLM и VeRL, батчинг и планирование, MoE-маршрутизация и прогнозирование отказов кластерного оборудования (память, сеть) — и превращает модели в надёжные высокодоступные сервисы с измеримым SLO.

ОПЫТ РАБОТЫ

Huawei — R&D-инженер по LLM-инференсу · Сентябрь 2024 — настоящее время

- Симулятор disaggregated Prefill/Decode — дискретно-событийное моделирование на C++ системы prefill/decode-обслуживания с балансировкой нагрузки с учётом KV-кэша и марковским трафиком запросов; выбор топологии TP/DP/SP/EP и политики планирования для удержания SLO 99,99%; восстановление vLLM для RL-прогонов.
- Кластеризация временных рядов телеметрии оптической мощности заранее выявляет деградирующие каналы; модель с минимальным числом параметров повысила доступность кластера на +10%.
- NUMA-осознанное стресс-тестирование достигло 95% теоретической пропускной способности; моделирование MTTR (распределение Вейбулла) + прогнозирование отказов (XGBoost) благодаря раннему предупреждению снизили издержки от ошибок памяти в big data приложениях в два раза. [📄 документация](#)
- Комбинаторные алгоритмы размещения экспертов MoE (EPLB), совместно оптимизирующие маппинг «эксперт → GPU» и all-to-all-коммуникации, чтобы минимизировать перегрузку сети и хвостовую задержку.
- Глубокое знание стека обслуживания: continuous batching и вытесняющее планирование, fused-коммуникации, квантизация FP8/INT8, спекулятивное декодирование и trade-off оптимизации.

ML-инженер — Университет ИТМО · Ноябрь 2023 — Сентябрь 2024

- Сбер и ИТМО: эмулятор пользователей на CTGAN; улучшил MAP@5 рекомендательной системы BiVAE на 3%.
- Алмазова и ИТМО: взвешенный XGBoost с весами Шепли для лечения ожирения; точность 71% в прогнозе ответа на терапию сибутрамином за 3 месяца; 2 статьи Q2.
- Промышленный ИИ-ассистент: улучшил NER по PDF с помощью prompt engineering/self-consistency; фильтрация убрала 80% повторов.

Инженер по тестированию — Harman · Сентябрь 2021 — Июль 2022

- Ускорил тестирование сложных автомобильных GPS-систем с помощью Robot Framework

intel **Release-инженер — Intel** · Июль 2019 – Август 2021

- Поддерживал release-инфраструктуру Intel OneAPI HPC: автоматизация на Python/Bash и инсталлятор на C++.

ТЕХНОЛОГИИ

- **AI-инфраструктура:** Harness, Agents workflow, RAG, CAG, vLLM, VeRL, PyTorch, Kubernetes
- **Анализ данных и исследования:** Python, Pandas, Scikit-learn, AutoML, PatentScope, Elsevier Scopus

ОБРАЗОВАНИЕ

Университет ИТМО, 2024 — магистратура по анализу данных

– Диплом: фильтрация с весами Шепли для ML на малых выборках; +7% точности на медицинских данных.

НИУ ВШЭ, 2022 — бакалавриат по программной инженерии

– Диплом: доступный ассистент для слабовидящих пользователей на базе Yandex Cloud OCR.

ПУБЛИКАЦИИ

- Google Scholar · индекс Хирша 2
- Danilov et al., J. Pers. Med. 2024, 14, 811 — прогнозирование терапии сибутрамином.
- Markina et al., J. Clin. Med. 2024, 13, 4151 — бурая жировая ткань и лечение ожирения.

ХАКАТОНЫ

ScienceRAG — исследовательский ассистент-агент на базе GigaChat

– ScienceRAG: улучшил RAG-поиск по arXiv на GigaChat  YouTube

X5 AI Tech Hackathon — алгоритм детекции галлюцинаций

– X5 AI Tech: детектор галлюцинаций на ruBERT — точность 88%, инференс <0,45 с; топ-10.

ЯЗЫКИ

- Русский, английский (B1)